

Министерство науки и высшего образования Российской Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО»
(Университет ИТМО)

Факультет
Программной инженерии и компьютерных технологий

РАСЧЕТНО-ГРАФИЧЕСКАЯ РАБОТА № 1

по дисциплине:

Математическая статистика

Вариант А-5

Выполнили:

Бармичев Григорий Андреевич

Тарнопольский Максим Николаевич

Проверил: Ланбин Юрий Владимирович

Оглавление

4.1 Первичное описание выборки	3
4.2. Предположение о виде закона распределения.....	7
4.3. Оценивание параметров: метод моментов и метод максимального правдоподобия .	7
1) Столбец X_1 , модель $\text{Exp}(\lambda, c)$	7
2) Столбец X_2 , модель $U(a, b)$	9
3) Столбец X_3 , модель $N(a, \sigma)$	10
Итоговая таблица	10
4.4. Оценивание параметрической вероятности двумя способами	11
1) Столбец X_1	11
2) Столбец X_2	11
3) Столбец X_3	12
Итоговая таблица	13
4.5. Оценка моментов по сгруппированной выборке	13
1) Столбец X_1	13
2) Столбец X_2	14
3) Столбец X_3	15
Итоговая таблица по пункту 4.5	16
4.6. Доверительные интервалы.....	16
1. Асимптотические доверительные интервалы для $E(X)$	16
2. Точные доверительные интервалы для нормального столбца X_3	17
Сравнение интервалов	18
3. Интерпретация доверительных интервалов.....	19
4.7. Итоговый вывод	19

4.1 Первичное описание выборки

Столбец X1


Вариационный ряд:

[19.97 20.01 20.08 20.15 20.76 22.09 22.28 23.65 24.02 24.44 25.72 25.77 25.99 26.34 27.13 27.64 27.67 28.09 28.34 28.96 29.05 30.26 30.76 30.99 31.19 31.31 31.47 32.19 34.41 34.52 34.56 34.78 34.88 35.09 35.7 36.52 36.73 36.87 37.16 37.21 37.65 38.21 38.46 38.68 39.56 40.45 40.49 40.6 40.82 41.65 42.42 42.58 43.29 44.05 44.83 45.1 45.37 45.63 45.76 46.68 47.06 47.84 48.28 48.54 49.14 49.73 50.05 50.83 50.89 51.1 53.51 53.66 54.56 54.57 55.71 56.43 59.12 59.45 59.72 60.8 62.87 62.96 63.44 64.03 65.35 66.16 66.49 68.15 68.24 68.76 70.58 70.98 72.44 74.28 74.86 74.93 75.14 75.26 75.36 75.51 76.32 79.81 80.1 80.62 81.79 82.34 89.76 90.28 90.77 91.54 93.7 94.08 94.17 94.73 95.92 97.19 98.57 100.86 101.07 101.61 104.46 105.47 110.01 113.98 114.77 115.67 116.12 116.52 117.8 118.66 119.6 120.46 121.09 123.57 124.91 125.22 125.87 126.72 128.05 130.73 132.17 135.72 138.28 139.39 141.41 145.07 145.54 147.6 147.84 148.14 148.65 150.26 152.2 155.43 156.71 159.63 164.7 166.44 167.08 167.54 170.34 174.19 185.48 188.1 191.56 193.53 196.5 197.12 201.55 208.54 220.78 222.68 223.36 230.06 233.38 240.58 241.91 251.14 253.35 255.09 257.63 279.48 279.63 279.98 287.05 289.44 304.71 305.38 316.03 318.71 321.77 326.12 355.39 362.81 380.89 463.58 496.43 497.16 538.43 579.58]

Числовые характеристики:

Характеристика	Значение
Объём выборки n	200
Среднее $\bar{x}$	115.9398
Дисперсия (смещённая) S^2	10866.0997
Дисперсия (несмещённая) $\hat{s}^2$	10920.7032
Стандартное отклонение S	104.2406
Стандартное отклонение $\hat{s}$	104.5022
Медиана me	75.9150
Первый квартиль $Q1$	42.2275
Третий квартиль $Q3$	148.2675
Минимум	19.97
Максимум	579.58
Число интервалов по Скотту	9
Ширина интервала h	62.3871

Графики:



Гистограмма имеет выраженную правостороннюю асимметрию: основная масса наблюдений сосредоточена в левой части, а вправо тянется длинный хвост. А также имеется выброс на промежутке 460–580.

Столбец X2

Вариационный ряд:


[24.99 25.09 25.14 25.4 25.57 25.79 25.84 25.91 26.01 26.11 26.27 26.82 26.83 27.58 28.67 28.79 29. 29.21 29.64 30.08 30.19 30.23 30.49 31.33 31.36 31.57 31.91 31.92 32.06 32.08 32.21 32.43 32.46 32.52 33.54 33.67 33.83 33.83 33.95 34.1 34.22 34.95 35.54 35.63 35.96 36.01 36.25 36.38 36.82 37.02 37.08 37.59 37.86 37.86 38.43 38.81 38.86 38.97 39.26 39.57 39.65 40.13 40.18 40.82 41.06 41.12 41.17 41.56 42.59 42.88 43.72 43.82 43.86 43.96 44.16 44.26 44.28 45.42 45.68 46.08 46.11 46.28 46.3 46.48 46.8 46.91 47.12 47.14 47.75 48.14 48.61 48.91 49.16 49.42 49.59 49.82 50.05 51.39 51.42 53.37 53.89 54.32 54.38 54.58 54.61 54.64 54.84 55.16 55.19 55.66 55.71 56.69 56.85 57.07 57.16 57.99 58.16 58.36 58.4 58.5 58.52 59.02 59.09 59.1 59.12 59.37 59.92 60.29 60.36 60.83 60.86 60.93 60.95 61.44 61.52 61.85 61.89 62.14 62.77 62.92 62.98 63.04 63.16 63.18 63.2 63.59 63.76 64.07 64.13 64.49 65.03 65.77 66.12 66.23 66.91 66.94 66.95 66.99 67.88 67.95 68.28 68.4 69.2 69.32 70.15 70.55 70.57 71.02 71.43 71.85 72.11 72.31 72.69 72.77 72.89 73.05 73.13 74.09 74.19 74.21 74.77 74.95 75.06 75.7 75.71 75.71 76.19 76.2 76.89 77.33 78.7 79.04 79.07 79.14 79.18 79.36 79.51 79.61 79.62 79.85]

Числовые характеристики:

Характеристика	Значение
Объем выборки n	200
Среднее $\bar{x}$	51.8794
Дисперсия (смещённая) S^2	266.3561

Дисперсия (несмещённая) $\hat{s}^2$	267.6946
Стандартное отклонение S	16.3204
Стандартное отклонение $\hat{s}$	16.3614
Медиана me	53.6300
Первый квартиль Q1	37.0650
Третий квартиль Q3	64.6250
Минимум	24.99
Максимум	79.85
Число интервалов по Скотту	6
Ширина интервала h	9.7676

Графики:



Гистограмма заполняет почти весь интервал значений достаточно ровно, без явных пиков и без длинных хвостов. Эмпирическая функция распределения возрастает почти линейно. Признаков выбросов и сильной асимметрии не наблюдается.

Столбец X3

Вариационный ряд:


[47.76 50.45 51.23 52.3 52.35 52.99 53.29 53.51 53.52 53.94 54.2 54.76 55.38 56.36 56.73 56.77 57.23 57.58 57.59 57.65 57.78 58.21 58.21 58.22 58.24 58.83 58.88 58.94 58.95 59.02 59.45 59.95 60.01 60.02 60.03 60.12 60.25 60.39 60.72 60.72 60.98 61. 61.03 61.36 61.53 61.85 61.92 61.97 62.03 62.14 62.43 62.47 62.53 62.86 62.94 63.07 63.11 63.15 63.49 63.57 64.04 64.07 64.07 64.09 64.11 64.11 64.26 64.48 64.68 64.95 64.96 65.2 65.24 65.42 65.59 65.67 65.71 65.72 65.89 65.89 65.94 66.04 66.42 66.51 66.53 66.55 66.6 66.7 66.85 66.86 67.08 67.1 67.24 67.28 67.31 67.38 67.41 67.57 67.66 67.73 68.23 68.4 68.46 68.48 68.7 68.77 68.85 68.92]

68.92 69.04 69.05 69.05 69.17 69.2 69.2 69.23 69.43 69.71 70.16 70.28 70.29 70.33 70.39 70.43
70.58 70.71 70.87 70.88 70.91 71.07 71.23 71.35 71.47 71.53 71.54 71.58 71.58 71.76 71.96
72.03 72.07 72.13 72.16 72.21 72.79 72.8 72.82 72.82 72.91 72.97 73.02 73.28 73.31 73.46
73.48 73.74 73.77 73.82 73.87 74.04 74.1 74.13 74.48 74.88 74.96 75.25 75.25 75.35 75.48
75.61 75.71 75.79 76.15 76.19 76.77 77.08 77.15 77.22 77.34 77.6 77.67 77.68 77.85 78.32
78.49 78.69 78.7 79. 79.07 79.64 79.88 80.54 80.72 81.24 81.32 81.59 81.72 82.1 83.17 85.21]

Числовые характеристики:

Характеристика	Значение
Объем выборки n	200
Среднее $\bar{x}$	67.6959
Дисперсия (смещённая) S^2	56.5674
Дисперсия (несмещённая) $\hat{s}^2$	56.8516
Стандартное отклонение S	7.5211
Стандартное отклонение $\hat{s}$	7.5400
Медиана m_e	67.9800
Первый квартиль Q1	62.3575
Третий квартиль Q3	72.9825
Минимум	47.76
Максимум	85.21
Число интервалов по Скотту	9
Ширина интервала h	4.5013

Графики:



Гистограмма одновершинная и близка к колоколообразной форме, левый и правый хвосты имеют сопоставимую длину. Распределение выглядит почти симметричным относительно центра около 68. Явных выбросов нет.

4.2. Предположение о виде закона распределения

По результатам первичного анализа выборки получены следующие гипотезы о виде закона распределения:

- Для столбца X1 наиболее подходящей моделью является экспоненциальное распределение со сдвигом $\text{Exp}(\lambda, c)$. Что согласуется с формой гистограммы, видом ЭФР и наличием естественной нижней границы около 20.
- Для столбца X2 наиболее подходящей моделью является равномерное распределение $U(a, b)$. Для него характерны почти постоянная высота гистограммы и почти линейная ЭФР на конечном отрезке.
- Для столбца X3 наиболее подходящей моделью является нормальное распределение $N(a, \sigma)$. Это Гистограмма имеет один центральный пик и близка к симметричной колоколообразной форме, а ЭФР плавную S-образной формы.

4.3. Оценивание параметров: метод моментов и метод максимального правдоподобия

1) Столбец X1, модель $\text{Exp}(\lambda, c)$

Для сдвинутого экспоненциального распределения: $EX = c + \frac{1}{\lambda}, DX = \frac{1}{\lambda^2}$

По выборке для X1: $\bar{x} = 115.9398, S^2 = 10866.0997, S = 104.2406, x_{(1)} = 19.97$.

Метод моментов

Приравниваем:

$$\bar{x} = c + \frac{1}{\lambda}, S^2 = \frac{1}{\lambda^2}$$

Отсюда:

$$\hat{\lambda}_{MM} = \frac{1}{S} = \frac{1}{104.2406} \approx 0.00959$$

$$\hat{c}_{MM} = \bar{x} - S = 115.9398 - 104.2406 = 11.6992$$

Метод максимального правдоподобия

Плотность:

$$f(x) = \begin{cases} \lambda e^{-\lambda(x-c)}, & x \geq c, \\ 0, & x < c. \end{cases}$$

Функция правдоподобия:

$$L(\lambda, c) = \prod_{i=1}^n \lambda e^{-\lambda(x_i-c)}$$

при условии $c \leq x_i$ для всех i :

$$L(\lambda, c) = \lambda^n \exp\left(-\lambda \sum_{i=1}^n (x_i - c)\right) = \lambda^n \exp\left(-\lambda \sum_{i=1}^n x_i + n\lambda c\right).$$

Чтобы правдоподобие было максимально по c , надо брать максимально возможное c , то есть

$$\hat{c}_{MLE} = x_{(1)} = 19.97.$$

Дальше при фиксированном c логарифм правдоподобия:

$$\ell(\lambda) = n \ln \lambda - \lambda \sum_{i=1}^n (x_i - c).$$

Производная:

$$\ell'(\lambda) = \frac{n}{\lambda} - \sum_{i=1}^n (x_i - c).$$

Приравниваем к нулю:

$$\frac{n}{\lambda} = \sum_{i=1}^n (x_i - c).$$

Отсюда:

$$\hat{\lambda}_{MLE} = \frac{n}{\sum_{i=1}^n (x_i - \hat{c}_{MLE})} = \frac{1}{\bar{x} - \hat{c}_{MLE}} = \frac{1}{115.9398 - 19.97} = \frac{1}{95.9698} \approx 0.01042.$$

Сравнение

Оценки близки по λ , но заметно различаются по параметру сдвига c . Это нормально, так как для экспоненциального распределения ММП берёт левую границу равной минимуму выборки, а метод моментов использует только среднее и дисперсию.

$$\hat{\lambda}_{MM} = 0.00959, \hat{c}_{MM} = 11.6992,$$

$$\hat{\lambda}_{MLE} = 0.01042, \hat{c}_{MLE} = 19.97.$$

2) Столбец X2, модель $U(a, b)$

Для равномерного распределения: $EX = \frac{a+b}{2}, DX = \frac{(b-a)^2}{12}$

По выборке для X2: $\bar{x} = 51.8794, S^2 = 266.3561, x_{(1)} = 24.99, x_{(n)} = 79.85$.

Метод моментов

Из второго уравнения:

$$b - a = \sqrt{12S^2} = \sqrt{12 \cdot 266.3561} = \sqrt{3196.2732} \approx 56.5356.$$

Из первого уравнения:

$$a + b = 2\bar{x} = 2 \cdot 51.8794 = 103.7588.$$

Решаем систему

$$\begin{cases} a + b = 103.7588, \\ b - a = 56.5356. \end{cases}$$

Получаем:

$$\hat{a}_{MM} = 23.6116; \hat{b}_{MM} = 80.1472.$$

Метод максимального правдоподобия

Плотность:

$$f(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b, \\ 0, & \text{иначе.} \end{cases}$$

Функция правдоподобия:

$$L(a, b) = \frac{1}{(b-a)^n}$$

при условии $a \leq x_{(1)}, x_{(n)} \leq b$.

Чтобы $L(a, b)$ была максимальной, нужно сделать длину интервала $b - a$ как можно меньше, но так, чтобы в него попадали все наблюдения. Значит,

$$\hat{a}_{MLE} = x_{(1)} = 24.99$$

$$\hat{b}_{MLE} = x_{(n)} = 79.85$$

Сравнение

Обе оценки дают почти один и тот же интервал. Метод моментов даёт немного более широкий интервал, а ММП точно опирается на минимальное и максимальное наблюдения.

$$\hat{a}_{MM} = 23.6116, \hat{b}_{MM} = 80.1472,$$

$$\hat{a}_{MLE} = 24.99, \hat{b}_{MLE} = 79.85.$$

3) Столбец X3, модель $N(a, \sigma)$

Для нормального распределения: $EX = a, DX = \sigma^2$

По выборке для X3: $\bar{x} = 67.6959, S^2 = 56.5674, S = 7.5211$.

Метод моментов

$$\hat{a}_{MM} = \bar{x}, \hat{\sigma}_{MM}^2 = S^2.$$

Получаем:

$$\hat{a}_{MM} = 67.6959, \hat{\sigma}_{MM}^2 = 56.5674, \hat{\sigma}_{MM} = 7.5211$$

Метод максимального правдоподобия

Для нормального распределения оценки ММП:

$$\hat{a}_{MLE} = \bar{x}, \hat{\sigma}_{MLE}^2 = S^2, \hat{\sigma}_{MLE} = S$$

Численно:

$$\hat{a}_{MLE} = 67.6959, \hat{\sigma}_{MLE}^2 = 56.5674, \hat{\sigma}_{MLE} = 7.5211$$

Сравнение

Для нормального распределения метод моментов и метод максимального правдоподобия дают одинаковые оценки параметров. Поэтому различий между результатами здесь нет.

$$\hat{a}_{MM} = \hat{a}_{MLE} = 67.6959, \hat{\sigma}_{MM} = \hat{\sigma}_{MLE} = 7.5211.$$

Итоговая таблица

Столбец	Модель	Метод моментов	ММП
X1	$\text{Exp}(\lambda, c)$	$\hat{\lambda} = 0.00959, \hat{c} = 11.6992$	$\hat{\lambda} = 0.01042, \hat{c} = 19.97$
X2	$U(a, b)$	$\hat{a} = 23.6116, \hat{b} = 80.1472$	$\hat{a} = 24.99, \hat{b} = 79.85$
X3	$N(a, \sigma)$	$\hat{a} = 67.6959, \hat{\sigma} = 7.5211$	$\hat{a} = 67.6959, \hat{\sigma} = 7.5211$

4.4. Оценивание параметрической вероятности двумя способами

1) Столбец X1

Возьмём порог: $x_0 = \bar{x} + \hat{\sigma} = 115.9398 + 104.5022 = 220.4420$.

Эмпирическая оценка

Количество наблюдений, для которых $x_i > x_0$: $m = 30$.

Так как $n = 200$, получаем:

$$\hat{p}_{\text{emp}} = \frac{30}{200} = 0.15.$$

Параметрическая оценка

Для сдвинутого экспоненциального распределения:

$$P(X > x) = e^{-\lambda(x-c)}, x \geq c.$$

Подставляем найденные оценки:

$$\hat{p}_{\text{par}} = e^{-\hat{\lambda}(x_0 - \hat{c})} = e^{-0.01042(220.4420 - 19.97)} = e^{-2.0892} \approx 0.1238.$$

Сравнение

$$\hat{p}_{\text{emp}} = 0.1500, \hat{p}_{\text{par}} = 0.1238.$$

$$|\hat{p}_{\text{emp}} - \hat{p}_{\text{par}}| = 0.0262.$$

Оценки достаточно близки. Небольшое расхождение связано с конечным объёмом выборки и тем, что реальная выборка не обязана идеально совпадать с теоретической моделью.

2) Столбец X2

Возьмём порог: $x_0 = \bar{x} + \hat{\sigma} = 51.8794 + 16.3614 = 68.2408$.

Эмпирическая оценка

Количество наблюдений выше порога: $m = 40$.

Получаем:

$$\hat{p}_{\text{emp}} = \frac{40}{200} = 0.20.$$

Параметрическая оценка

Для равномерного распределения на $[a, b]$:

$$P(X > x) = \frac{b - x}{b - a}, a \leq x \leq b.$$

Подставляем:

$$\hat{p}_{\text{par}} = \frac{\hat{b} - x_0}{\hat{b} - \hat{a}} = \frac{79.85 - 68.2408}{79.85 - 24.99} = \frac{11.6092}{54.86} \approx 0.2116.$$

Сравнение

$$\hat{p}_{\text{emp}} = 0.2000, \hat{p}_{\text{par}} = 0.2116.$$

$$|\hat{p}_{\text{emp}} - \hat{p}_{\text{par}}| = 0.0116.$$

Оценки очень близки.

3) Столбец X3

Возьмём порог: $x_0 = \bar{x} + \hat{\sigma}_{\text{испр}} = 67.6959 + 7.5400 = 75.2359$.

Эмпирическая оценка

Количество наблюдений выше порога: $m = 35$.

Следовательно,

$$\hat{p}_{\text{emp}} = \frac{35}{200} = 0.175.$$

Параметрическая оценка

Для нормального распределения:

$$P(X > x_0) = 1 - \Phi\left(\frac{x_0 - a}{\sigma}\right).$$

Подставляем оценки:

$$\hat{p}_{\text{par}} = 1 - \Phi\left(\frac{75.2359 - 67.6959}{7.5211}\right) = 1 - \Phi(1.0025) \approx 0.1580.$$

Сравнение

$$\hat{p}_{\text{emp}} = 0.1750, \hat{p}_{\text{par}} = 0.1580.$$

$$|\hat{p}_{\text{emp}} - \hat{p}_{\text{par}}| = 0.0170.$$

Расхождение небольшое, значит нормальная модель для X_3 хорошо описывает хвост вероятностей в районе выбранного порога.

Итоговая таблица

Столбец	$x_0 = \bar{x} + \hat{\sigma}$	Эмпирическая оценка	Параметрическая оценка
X1	220.4420	0.1500	0.1238
X2	68.2408	0.2000	0.2116
X3	75.2359	0.1750	0.1580

4.5. Оценка моментов по сгруппированной выборке

1) Столбец X1

Для X_1 было взято $m = 9$ интервалов.

Таблица интервального ряда:

№	Интервал	Середина $\hat{X}_k$	Частота n_k
1	[19.97; 82.15)	51.0594	105
2	[82.15; 144.33)	113.2383	40
3	[144.33; 206.51)	175.4172	24
4	[206.51; 268.69)	237.5961	12
5	[268.69; 330.86)	299.7750	11
6	[330.86; 393.04)	361.9539	3
7	[393.04; 455.22)	424.1328	0
8	[455.22; 517.40)	486.3117	3
9	[517.40; 579.58]	548.4906	2

Оценка среднего по сгруппированной выборке:

$$\hat{X}_g = \frac{1}{200} \sum_{k=1}^9 n_k \hat{X}_k = \frac{1}{200} (23891.2444) = 119.4562.$$

Оценка дисперсии по сгруппированной выборке:

$$\hat{\sigma}_g^2 = \frac{1}{199} \sum_{k=1}^9 n_k (\hat{X}_k - \hat{X}_g)^2 = \frac{1}{199} (2041361.1100) = 10258.0960.$$

Сравнение с исходной выборкой

По исходным данным:

$$\bar{x} = 115.9398, \hat{\sigma}^2 = 10920.7032.$$

По сгруппированной выборке:

$$\hat{X}_g = 119.4562, \hat{\sigma}_g^2 = 10258.0960.$$

Разности:

$$| 119.4562 - 115.9398 | = 3.5164;$$

$$| 10258.0960 - 10920.7032 | = 662.6072.$$

Для X_1 расхождение заметнее, чем у остальных столбцов. Это естественно, потому что распределение сильно асимметрично и имеет длинный правый хвост, а при группировке часть информации теряется.

2) Столбец X_2

Для X_2 было взято $m = 6$ интервалов.

№	Интервал	Середина $\hat{X}_k$	Частота n_k
1	[24.99; 34.13)	29.5617	40
2	[34.13; 43.28)	38.7050	30
3	[43.28; 52.42)	47.8483	29
4	[52.42; 61.56)	56.9917	36
5	[61.56; 70.71)	66.1350	32
6	[70.71; 79.85]	75.2783	33

Оценка среднего

$$\hat{X}_g = \frac{1}{200} \sum_{k=1}^6 n_k \hat{X}_k = \frac{1}{200} (10383.4233) = 51.9171.$$

Оценка дисперсии

$$\hat{\sigma}_g^2 = \frac{1}{199} \sum_{k=1}^6 n_k (\hat{X}_k - \hat{X}_g)^2 = \frac{1}{199} (51112.9549) = 256.8490.$$

Сравнение с исходной выборкой

По исходной выборке:

$$\bar{x} = 51.8794, \hat{\sigma}^2 = 267.6946.$$

По сгруппированной:

$$\hat{X}_g = 51.9171, \hat{\sigma}_g^2 = 256.8490.$$

Разности:

$$| 51.9171 - 51.8794 | = 0.0377,$$

$$| 256.8490 - 267.6946 | = 10.8456.$$

Оценки очень близки. Для X_2 группировка почти не исказила результат.

3) Столбец X_3

Для X_3 было взято $m = 9$ интервалов.

№	Интервал	Середина $\hat{X}_k$	Частота n_k
1	[47.76; 51.92)	49.8406	3
2	[51.92; 56.08)	54.0017	10
3	[56.08; 60.24)	58.1628	23
4	[60.24; 64.40)	62.3239	31
5	[64.40; 68.57)	66.4850	37
6	[68.57; 72.73)	70.6461	40
7	[72.73; 76.89)	74.8072	31
8	[76.89; 81.05)	78.9683	18
9	[81.05; 85.21]	83.1294	7

Оценка среднего

$$\hat{X}_g = \frac{1}{200} \sum_{k=1}^9 n_k \hat{X}_k = \frac{1}{200} (13567.4722) = 67.8374.$$

Оценка дисперсии

$$\hat{\sigma}_g^2 = \frac{1}{199} \sum_{k=1}^9 n_k (\hat{X}_k - \hat{X}_g)^2 = \frac{1}{199} (11737.3010) = 58.9814.$$

Сравнение с исходной выборкой

По исходным данным:

$$\bar{x} = 67.6959, \hat{\sigma}^2 = 56.8516.$$

По сгруппированной выборке:

$$\hat{X}_g = 67.8374, \hat{\sigma}_g^2 = 58.9814.$$

Разности:

$$| 67.8374 - 67.6959 | = 0.1415,$$

$$| 58.9814 - 56.8516 | = 2.1298.$$

Оценки достаточно близки, следовательно, для X_3 группировка тоже почти не ухудшает результат.

Итоговая таблица по пункту 4.5

Столбец	$\bar{x}$	$\hat{X}_g$	$\hat{\sigma}^2$
X1	115.9398	119.4562	10920.7032
X2	51.8794	51.9171	267.6946
X3	67.6959	67.8374	56.8516

4.6. Доверительные интервалы

Зафиксируем уровень доверия $1 - \alpha = 0.95, \alpha = 0.05$.

Тогда: $z_{1-\alpha/2} = z_{0.975} \approx 1.96$.

1. Асимптотические доверительные интервалы для $E(X)$

Столбец X1

По выборке:

$$\bar{x} = 115.9398, \hat{\sigma} = 104.5022, n = 200.$$

Стандартная ошибка:

$$\frac{\hat{\sigma}}{\sqrt{n}} = \frac{104.5022}{\sqrt{200}} \approx \frac{104.5022}{14.1421} \approx 7.3894.$$

Половина длины интервала:

$$1.96 \cdot 7.3894 \approx 14.4830.$$

Получаем:

$$I_{0.95}(E(X_1)) = (115.9398 - 14.4830; 115.9398 + 14.4830) = (101.4568; 130.4228)$$

Столбец X2

По выборке:

$$\bar{x} = 51.8794, \hat{\sigma} = 16.3614, n = 200.$$

Стандартная ошибка:

$$\frac{\hat{\sigma}}{\sqrt{n}} = \frac{16.3614}{14.1421} \approx 1.1569.$$

Половина длины интервала:

$$1.96 \cdot 1.1569 \approx 2.2675.$$

Получаем:

$$I_{0.95}(E(X_2)) = (51.8794 - 2.2675; 51.8794 + 2.2675) = (49.6119; 54.1469)$$

Столбец X3

По выборке:

$$\bar{x} = 67.6959, \hat{\sigma} = 7.5400, n = 200.$$

Стандартная ошибка:

$$\frac{\hat{\sigma}}{\sqrt{n}} = \frac{7.5400}{14.1421} \approx 0.5332.$$

Половина длины интервала:

$$1.96 \cdot 0.5332 \approx 1.0450.$$

Получаем:

$$I_{0.95}(E(X_3)) = (67.6959 - 1.0450; 67.6959 + 1.0450) = (66.6509; 68.7408)$$

2. Точные доверительные интервалы для нормального столбца X3

2.1. Точный доверительный интервал для μ при неизвестной σ^2

Если $X \sim N(\mu, \sigma^2)$, то при неизвестной дисперсии точный доверительный интервал для μ имеет вид:

$$\bar{x} \pm t_{1-\alpha/2; n-1} \frac{\hat{\sigma}}{\sqrt{n}}.$$

Получаем:

$$t_{0.975; 199} \approx 1.972.$$

Для X3:

$$\bar{x} = 67.6959, \hat{\sigma} = 7.5400, n = 200.$$

Половина длины интервала:

$$1.972 \cdot \frac{7.5400}{\sqrt{200}} = 1.972 \cdot 0.5332 \approx 1.0514.$$

Получаем:

$$I_{0.95}(\mu) = (67.6959 - 1.0514; 67.6959 + 1.0514) = (66.6445; 68.7472)$$

2.2. Точный доверительный интервал для σ^2

Для нормальной выборки:

$$\frac{(n-1)\hat{\sigma}^2}{\sigma^2} \sim \chi_{n-1}^2.$$

Отсюда точный доверительный интервал для дисперсии:

$$\left(\frac{(n-1)\hat{\sigma}^2}{\chi_{1-\alpha/2; n-1}^2}, \frac{(n-1)\hat{\sigma}^2}{\chi_{\alpha/2; n-1}^2} \right).$$

Для X3:

$$\hat{\sigma}^2 = 56.8516, n = 200, n - 1 = 199.$$

Квантили распределения:

$$\chi_{0.975; 199}^2 \approx 239.9597, \chi_{0.025; 199}^2 \approx 161.8262.$$

Сначала считаем числитель:

$$(n-1)\hat{\sigma}^2 = 199 \cdot 56.8516 \approx 11313.4737.$$

Левая граница:

$$\frac{11313.4737}{239.9597} \approx 47.1474.$$

Правая граница:

$$\frac{11313.4737}{161.8262} \approx 69.9113.$$

Получаем:

$$I_{0.95}(\sigma^2) = (47.1474; 69.9113)$$

Сравнение интервалов

Для математического ожидания получили:

$$I_{0.95}(E(X_1)) = (101.4568; 130.4228)$$

$$I_{0.95}(E(X_2)) = (49.6119; 54.1469)$$

$$I_{0.95}(E(X_3)) = (66.6509; 68.7408)$$

Для нормального столбца X3 дополнительно:

$$I_{0.95}(\mu) = (66.6445; 68.7472)$$

$$I_{0.95}(\sigma^2) = (47.1474; 69.9113)$$

Заметим, что для X_3 асимптотический интервал для $E(X)$ и точный интервал для μ почти совпали. Это ожидаемо, потому что выборка относительно большая ($n = 200$).

3. Интерпретация доверительных интервалов

Доверительный интервал уровня 0.95 означает, что если многократно повторять процедуру построения интервала по независимым выборкам того же объёма, то примерно в 95% случаев построенный интервал будет покрывать истинное значение параметра. Это утверждение относится не к уже найденному числовому интервалу, а к самой процедуре его построения. После того как интервал уже построен, параметр считается фиксированным, а интервал — вычисленным по данным, поэтому говорить, что параметр находится в нём с вероятностью 0.95, строго говоря, неверно. Правильнее говорить, что интервал построен с доверительной вероятностью 0.95.

4.7. Итоговый вывод

По результатам анализа для столбца X_1 была выбрана модель сдвинутого экспоненциального распределения $Exp(\lambda, c)$ с оценками $\hat{\lambda} = 0.01042$ и $\hat{c} = 19.97$. Для столбца X_2 выбрана равномерная модель $U(a, b)$ с оценками $\hat{a} = 24.99$ и $\hat{b} = 79.85$. Для столбца X_3 наилучшей оказалась нормальная модель $N(a, \sigma)$, где $\hat{a} = 67.6959$ и $\hat{\sigma} = 7.5211$.

Асимптотические доверительные интервалы для математического ожидания показали, что самый широкий интервал имеет столбец X_1 : (101.4568; 130.4228), что связано с большой дисперсией и выраженной асимметрией. Для X_2 интервал уже: (49.6119; 54.1469), а для X_3 он самый узкий: (66.6509; 68.7408), что говорит о более устойчивом и предсказуемом поведении данных. Для нормального столбца X_3 дополнительно был построен точный доверительный интервал для дисперсии: (47.1474; 69.9113).