

Министерство науки и высшего образования Российской Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО»
(Университет ИТМО)

Факультет
Программной инженерии и компьютерных технологий

РАСЧЕТНО-ГРАФИЧЕСКАЯ РАБОТА № 3

по дисциплине:

Математическая статистика

Вариант А-5

Выполнили:

Бармичев Григорий Андреевич

Тарнопольский Максим Николаевич

Проверил: Ланбин Юрий Владимирович

Оглавление

4.1. Первичный анализ данных	3
4.2. Построение трёх регрессионных моделей.....	4
4.3. Сравнение моделей	6
4.4. Подробный статистический анализ линейной модели	9
4.5. Прогноз и интерпретация	11
4.6. Итоговый вывод	11

4.1. Первичный анализ данных

Источник и срез

- Набор данных: openintro::ssd_speed - SSD read and write speeds
- Страница-источник: https://vincentarelbundock.github.io/Rdatasets/doc/openintro/ssd_speed.html
- Как получен срез: Набор openintro::ssd_speed без дополнительных фильтров.
- Фактор x: Скорость чтения, МБ/с (read)
- Отклик y: Скорость записи, МБ/с (write)
- Число наблюдений: $n = 54$

Фрагмент исходной таблицы:

i	x, МБ/с	y, МБ/с
1	376,0	361,0
2	408,0	419,0
3	442,0	385,0
4	443,0	381,0
5	445,0	389,0
6	448,0	390,0
7	456,0	418,0
8	459,0	420,0
9	463,0	428,0
10	465,0	407,0

По результатам загрузки данных получены следующие основные характеристики:

Показатель	x, МБ/с	y, МБ/с
Количество наблюдений	54	54
Среднее значение	1128,963	1090,963
Стандартное отклонение	702,906	804,733
Минимум	376,000	359,000
Медиана	1057,000	688,000
Максимум	2381,000	3144,000

Для предварительного анализа была построена диаграмма рассеяния точек (x_i, y_i) .



По диаграмме рассеяния видно, что между скоростью чтения и скоростью записи наблюдается положительная зависимость. При этом точки расположены не строго вдоль одной прямой, наблюдается заметный разброс значений, особенно при больших скоростях чтения.

Предварительная гипотеза:

Зависимость между x и y является возрастающей. В качестве базового предположения можно рассматривать линейную связь, однако из-за разброса точек и возможной кривизны зависимости необходимо дополнительно проверить квадратичную и степенную модели.

4.2. Построение трёх регрессионных моделей

Для оценки параметров моделей использовался метод наименьших квадратов. Расчёты были выполнены в Python с использованием библиотек `pandas`, `numpy` и `matplotlib`.

1. Линейная модель

Линейная модель имеет вид:

$$y = a + bx$$

По результатам расчётов получены следующие оценки параметров:

$$a = -24,357755, \quad b = 0,987916$$

Следовательно, итоговое уравнение линейной регрессии:

$$\hat{y} = -24,357755 + 0,987916x$$

Коэффициент $b > 0$, поэтому линейная модель показывает положительную зависимость: при увеличении скорости чтения SSD на 1 МБ/с прогнозируемая скорость записи в среднем увеличивается примерно на 0,988МБ/с.

2. Квадратичная модель

Квадратичная модель имеет вид:

$$y = a + bx + cx^2$$

По результатам расчётов получены оценки:

$$a = -291,299547, \quad b = 1,603151, \quad c = -0,0002430461$$

Итоговое уравнение квадратичной модели:

$$\hat{y} = -291,299547 + 1,603151x - 0,0002430461x^2$$

Так как коэффициент при x^2 отрицательный, график модели представляет собой параболу, ветви которой направлены вниз. Это означает, что модель допускает замедление роста скорости записи при больших значениях скорости чтения.

3. Степенная модель

Степенная модель имеет вид:

$$y = ax^b$$

Для оценки параметров степенной модели была выполнена линеаризация. Прологарифмируем обе части уравнения:

$$\ln y = \ln a + b \ln x$$

После замены переменных $Y = \ln y$, $X = \ln x$ получаем линейную модель:

$$Y = \ln a + bX$$

По результатам расчётов:

$$\ln a = -0,364635, \quad a = e^{-0,364635} = 0,694450, \quad b = 1,040228$$

Итоговое уравнение степенной модели:

$$\hat{y} = 0,694450x^{1,040228}$$

Так как показатель степени $b > 1$, модель описывает возрастающую зависимость: при увеличении скорости чтения прогнозируемая скорость записи также увеличивается.


Прогнозные значения моделей

Для каждого наблюдения были найдены прогнозные значения $\hat{y}_i$ по всем трём моделям. Фрагмент таблицы прогнозов представлен ниже.

i	x	y	Линейная модель	Квадратичная модель	Степенная модель
1	376,0	361,0	347,099	277,124	331,455
2	408,0	419,0	378,712	322,328	360,848
3	442,0	385,0	412,301	369,811	392,179
4	443,0	381,0	413,289	371,199	393,102
5	445,0	389,0	415,265	373,974	394,948
6	448,0	390,0	418,229	378,132	397,718
7	456,0	418,0	426,132	389,199	405,109
8	459,0	420,0	429,096	393,342	407,882
9	463,0	428,0	433,047	398,858	411,580
10	465,0	407,0	435,023	401,613	413,429

Графическое представление моделей

Регрессионные модели для зависимости скорости записи SSD от скорости чтения



4.3. Сравнение моделей

Для сравнения качества построенных регрессионных моделей были рассмотрены следующие показатели:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}, \quad RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}, \quad A = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

где R^2 — коэффициент детерминации, $RMSE$ — среднеквадратичная ошибка, A — средняя ошибка аппроксимации.

Для трёх построенных моделей были получены следующие значения показателей качества.

Модель	RSS	R^2	RMSE	A
Линейная модель	8765550,312	0,744613	402,896	18,849
Квадратичная модель	8436789,102	0,754191	395,268	18,358
Степенная модель	8921402,386	0,740072	406,462	16,740

По результатам расчётов лучшей по значениям R^2 , RSS и $RMSE$ оказалась квадратичная модель. Для неё получены следующие показатели:

$$R^2 = 0,754191, \quad RSS = 8436789,102, \quad RMSE = 395,268$$

Это означает, что квадратичная модель объясняет примерно 75,42% изменчивости скорости записи SSD и даёт наименьшие абсолютные ошибки среди трёх моделей.

По средней ошибке аппроксимации лучший результат показала степенная модель:


$$A = 16,740\%$$

Однако по основным абсолютным метрикам качества она уступает квадратичной модели.

Анализ остатков


Были построены графики остатков: $e_i = y_i - \hat{y}_i$

Линейная модель




Для линейной модели остатки расположены вокруг нуля, однако при больших значениях скорости чтения наблюдается значительный разброс. Это показывает, что линейная модель в целом отражает направление зависимости, но не полностью учитывает особенности данных.

Квадратичная модель



Для квадратичной модели остатки также имеют заметный разброс, однако по сравнению с линейной моделью значения RSS и $RMSE$ меньше. Это говорит о том, что квадратичная модель за счёт небольшого изгиба немного точнее приближает исходные данные.

Степенная модель



Для степенной модели средняя относительная ошибка аппроксимации оказалась наименьшей, однако по абсолютным ошибкам и коэффициенту детерминации она уступает квадратичной модели. Остатки также имеют заметный разброс, особенно при больших значениях x .

Вывод

По результатам сравнения можно сделать вывод, что квадратичная модель лучше всего описывает наблюдаемую зависимость. Она имеет наилучшие значения R^2 , RSS и $RMSE$. При этом различия между моделями не очень большие, поэтому зависимость можно считать в целом возрастающей и близкой к линейной, но с небольшим нелинейным эффектом.

4.4. Подробный статистический анализ линейной модели

Линейная модель:

$$\hat{y} = -24,357755 + 0,987916x$$

Несмещенная оценка дисперсии ошибки:

$$s^2 = \frac{RSS}{n - 2} = \frac{8765550.312}{54 - 2} = 168568.275$$

$$s = \sqrt{s^2} = 410.571$$

Остаточная сумма квадратов:

$$RSS = 8765550,312$$

Доверительные интервалы для коэффициентов линейной регрессии:

Число степеней свободы: $df = n - 2 = 52$

Квантиль Стьюдента: $t_{0.975, 52} \approx 2.007$

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = 26186057.925926$$

$$SE(b) = \frac{s}{\sqrt{S_{xx}}} = \frac{410.571}{\sqrt{26186057.925926}} = 0.080233$$

$$SE(a) = s \sqrt{\frac{1}{n} + \frac{(\bar{x})^2}{S_{xx}}} = 410.571 \sqrt{\frac{1}{54} + \frac{(1128.964)^2}{26192489}} = 106.4$$

Доверительный интервал для b: $0.987916 \pm 2.007 \cdot 0.0802$

$$CI_b = (0.827, 1.149)$$

Доверительный интервал для a: $-24.3578 \pm 2.007 \cdot 106.4$

$$CI_a = (-237.9, 189.2)$$

Вывод по доверительным интервалам:

- Интервал для b не содержит 0, следовательно коэффициент значим.
- Интервал для a содержит 0, следовательно свободный член статистически не отличается от нуля.

Проверка гипотезы:

$$t_{\text{набл}} = \frac{b}{SE(b)} = \frac{0.987916}{0.080233} = 12.32$$

$|12.32| > 2.007$, следовательно гипотеза H_0 отвергается

Коэффициент при x значимо отличается от нуля на уровне $\alpha=0.05$.

Связь между скоростью чтения и скоростью записи SSD является статистически значимой.

4.5. Прогноз и интерпретация

$$x^* = 1207,9904$$

Линейная модель:

$$\hat{y}_{\text{лин}} = -24,357755 + 0,987916 \cdot 1207,9904 \approx 1169,04$$

Квадратичная модель:

$$\hat{y}_{\text{квадр}} = -291,299547 + 1,603151 \cdot 1207,9904 - 0,0002430461 \cdot 1207,9904^2 \approx 1290,63$$

Степенная модель:

$$\hat{y}_{\text{степ}} = 0,694450 \cdot 1207,9904^{1,040228} \approx 1116,07$$

Основной выбрана квадратичная модель, потому что:

- Наибольший $R^2 = 0.754191$;
- Наименьшие RSS и RMSE

Прогноз: При скорости чтения SSD 1208 МБ/с ожидаемая скорость записи по квадратичной модели составляет ≈ 1291 МБ/с.

Интерполяция: Для SSD-накопителя, скорость чтения которого на 7% выше среднего по выборке (≈ 1129 МБ/с), прогнозируемая скорость записи достигает около 1291 МБ/с.

Квадратичная модель предсказывает более высокую скорость записи, чем линейная (1169 МБ/с) и степенная (1119 МБ/с), поскольку она лучше улавливает нелинейность в области средних и высоких значений. Это означает, что прирост скорости чтения даёт ускоряющийся прирост скорости записи.

4.6. Итоговый вывод

В данной работе исследовалась зависимость между скоростью чтения (x) и скоростью записи (y) SSD-накопителей на основе реального набора данных `openintro::ssd_speed` (54 наблюдения). Были построены три регрессионные модели: линейная, квадратичная и степенная.

Анализ показал, что связь является положительной, но не строго линейной: при малых и средних скоростях чтения рост записи близок к линейному, однако при больших значениях наблюдается небольшое замедление. Наилучшие абсолютные метрики (

R^2 , RMSE, RSS) демонстрирует квадратичная модель, которая объясняет $\approx 75\%$ изменчивости скорости записи.

Статистический анализ линейной модели подтвердил высокую значимость влияния скорости чтения. Для прогностических задач рекомендуется использовать квадратичную модель, так как она точнее описывает нелинейный эффект.