

Федеральное государственное автономное образовательное учреждение высшего
образования «Национальный исследовательский университет ИТМО»

Факультет Программной Инженерии и Компьютерной Техники

Домашнее задание
по дисциплине «Методы оптимизации»
Вариант 11

Выполнил:
Бармичев Григорий Андреевич
Группа Р3210
Проверил:
Селина Елена Георгиевна

Блок №1

Задание

Для тех же данных по варианту выполните решение методом кубической аппроксимации. Напишите программу, генерирующую последовательность приближений, на одном из языков программирования, используя $\varepsilon=0.0001$ для критерия останова.

Реализуйте программно визуализацию исходной и аппроксимирующей функций в одной координатной плоскости для итерации алгоритма, постройте визуализации для нескольких итераций.

Данные по варианту: $f(x) = x^3 - 3 \sin x$, $[a, b] = [0, 1]$

Производные функции

Исходная функция:

$$f(x) = x^3 - 3 \sin x$$

Первая производная:

$$f'(x) = 3x^2 - 3 \cos x$$

Вторая производная:

$$f''(x) = 6x + 3 \sin x$$

Проверим значения производной на концах отрезка:

$$\begin{aligned} f'(0) &= 3 \cdot 0^2 - 3 \cos 0 = -3 \\ f'(1) &= 3 \cdot 1^2 - 3 \cos 1 \approx 1.3791 \end{aligned}$$

Так как $f'(0) < 0$, $f'(1) > 0$, то точка минимума находится внутри отрезка $[0, 1]$.

Метод кубической аппроксимации

Метод кубической аппроксимации используется для поиска экстремума функции одной переменной. На каждой итерации на текущем отрезке $[a_k, b_k]$ строится кубическая аппроксимация функции. Для построения аппроксимации используются значения: $f(a_k)$, $f(b_k)$, $f'(a_k)$, $f'(b_k)$

Введём обозначения:

$$z_k = 3 \frac{f(a_k) - f(b_k)}{b_k - a_k} + f'(a_k) + f'(b_k), \quad w_k = \sqrt{z_k^2 - f'(a_k)f'(b_k)}$$

Тогда новая точка приближения находится по формуле:

$$x_k = b_k - (b_k - a_k) \frac{f'(b_k) + w_k - z_k}{f'(b_k) - f'(a_k) + 2w_k}$$

После нахождения точки x_k проверяется знак производной.

Если $f'(x_k) > 0$, то минимум находится левее точки x_k , поэтому: $b_{k+1} = x_k$

Если $f'(x_k) < 0$, то минимум находится правее точки x_k , поэтому: $a_{k+1} = x_k$

Критерий останова: $|f'(x_k)| < \varepsilon$

Ручное вычисление

Рассмотрим начальный отрезок: $a_0 = 0$, $b_0 = 1$

Вычислим значения функции и производной на концах отрезка:

$$\begin{aligned} f(0) &= 0^3 - 3 \sin 0 = 0, & f(1) &= 1^3 - 3 \sin 1 \approx -1.524413 \\ f'(0) &= 3 \cdot 0^2 - 3 \cos 0 = -3, & f'(1) &= 3 \cdot 1^2 - 3 \cos 1 \approx 1.379093 \end{aligned}$$

Вычислим вспомогательную величину z_0 :

$$z_0 = 3 \frac{0 - (-1.524413)}{1 - 0} - 3 + 1.379093 \approx 2.952332$$

Теперь найдём w_0 :

$$w_0 = \sqrt{2.952332^2 - (-3) \cdot 1.379093} \approx 3.585184$$

Новая точка приближения:

$$x_1 = 1 - 1 \cdot \frac{1.379093 + 3.585184 - 2.952332}{1.379093 - (-3) + 2 \cdot 3.585184} \approx 0.825797$$

Вычислим значение производной в найденной точке:

$$f'(0.825797) \approx 0.011912$$

Так как $f'(x_1) > 0$, то минимум находится левее, новый отрезок: $[a_1, b_1] = [0, 0.825797]$

Для 2 итерации аналогично получаем:

$$\begin{aligned} a_1 &= 0, b_1 = 0.825797 \\ z_1 &\approx 2.977492 \\ w_1 &\approx 2.983487 \\ x_2 &\approx 0.824151 \\ f'(x_2) &\approx 0.000131 \end{aligned}$$

Так как $f'(x_2) > 0$, то снова сужаем отрезок справа: $[a_2, b_2] = [0, 0.824151]$

Для 3 итерации:

$$\begin{aligned} a_2 &= 0, b_2 = 0.824151 \\ z_2 &\approx 2.977668 \\ w_2 &\approx 2.977734 \\ x_3 &\approx 0.824133 \\ f'(x_3) &\approx 0.000001 \end{aligned}$$

Поскольку $|f'(x_3)| < 0.0001$ критерий остановки выполнен. Следовательно, найденная точка минимума: $x^* \approx 0.824133$

Таблица итераций

№	a_k	b_k	x_k	$f(x_k)$	$f'(x_k)$
1	0.000000	1.000000	0.825797	-1.642120	0.011912
2	0.000000	0.825797	0.824151	-1.642130	0.000131
3	0.000000	0.824151	0.824133	-1.642130	0.000001

Визуализация кубической аппроксимации

Для визуализации на каждой итерации строилась исходная функция $f(x) = x^3 - 3 \sin x$ и кубическая аппроксимирующая функция $P(x)$.



Кубическая аппроксимация строилась в виде интерполяционного многочлена Эрмита. Пусть текущий отрезок равен $[a, b]$. Тогда: $t = \frac{x-a}{b-a}$


Аппроксимирующая функция имеет вид:

$$P(x) = (2t^3 - 3t^2 + 1)f(a) + (t^3 - 2t^2 + t)(b-a)f'(a) + (-2t^3 + 3t^2)f(b) + (t^3 - t^2)(b-a)f'(b)$$

Этот многочлен совпадает с исходной функцией и её производной на концах текущего отрезка.

Получившиеся графики:





Вывод по Блоку №1

В ходе выполнения домашнего задания был реализован метод кубической аппроксимации для функции: $f(x) = x^3 - 3\sin x$ на отрезке: $[0, 1]$.

С помощью программы была получена последовательность приближений. Метод завершил работу за 3 итерации, так как было выполнено условие $|f'(x^*)| < 0.0001$

Найденная точка минимума: $x^* \approx 0.824133$

Значение функции в этой точке: $f(x^*) \approx -1.642130$

Также были построены графики исходной функции и кубической аппроксимации для нескольких итераций алгоритма.

Блок №2

Задание Д32.1

Напишите программу для визуализации линий уровня целевой функции и ломаной последовательных приближений. Адаптируйте код для своего решения и модифицируйте его так, чтобы линии уровня целевой функции проходили строго через вершины ломаной приближений (количество линий должно быть равно количеству приближений). Приближения итеративно порождаются с помощью метода оптимизации до выполнения критерия останова. Постройте визуализацию для каждого метода оптимизации из ЛР4.

Данные по варианту: $f(x_1, x_2) = 2x_1^2 + 2x_1x_2 + 3x_2^2 - 12x_1 - 6x_2 + 18$, $x^{(0)} = (-2, 4)$.

Градиент функции

Исходная функция:

$$f(x_1, x_2) = 2x_1^2 + 2x_1x_2 + 3x_2^2 - 12x_1 - 6x_2 + 18$$

Производная по x_1 :

$$\frac{\partial f}{\partial x_1} = 4x_1 + 2x_2 - 12$$

Производная по x_2 :

$$\frac{\partial f}{\partial x_2} = 2x_1 + 6x_2 - 6$$

Градиент функции имеет вид:

$$\nabla f(x_1, x_2) = \begin{pmatrix} 4x_1 + 2x_2 - 12 \\ 2x_1 + 6x_2 - 6 \end{pmatrix}$$

Матрица Гессе:

$$H = \begin{pmatrix} 4 & 2 \\ 2 & 6 \end{pmatrix}$$

Точка минимума функции

Для нахождения стационарной точки решим систему:

$$\nabla f(x_1, x_2) = 0$$

То есть:

$$\begin{cases} 4x_1 + 2x_2 - 12 = 0 \\ 2x_1 + 6x_2 - 6 = 0 \end{cases}$$

Из уравнения получаем:

$$x_1 = 3, \quad x_2 = 0$$

Стационарная точка:

$$x^* = (3, 0)$$

Так как матрица Гессе положительно определена, то точка $x^* = (3, 0)$ является точкой минимума.

$$H = \begin{pmatrix} 4 & 2 \\ 2 & 6 \end{pmatrix}$$
$$\Delta_1 = 4 > 0; \quad \Delta_2 = \begin{vmatrix} 4 & 2 \\ 2 & 6 \end{vmatrix} = 4 \cdot 6 - 2 \cdot 2 = 20 > 0$$

Значение функции в точке минимума:

$$f(3, 0) = 2 \cdot 3^2 + 2 \cdot 3 \cdot 0 + 3 \cdot 0^2 - 12 \cdot 3 - 6 \cdot 0 + 18 = 18 - 36 + 18 = 0$$

Итак:

$$x^* = (3, 0), \quad f(x^*) = 0$$

Метод покоординатного спуска

Метод покоординатного спуска заключается в том, что на каждой итерации минимизация выполняется только по одной координате, а остальные координаты считаются фиксированными.

Для данной функции формулы обновления координат можно получить из условий:

$$\frac{\partial f}{\partial x_1} = 0, \quad 4x_1 + 2x_2 - 12 = 0$$

Отсюда:

$$x_1 = 3 - \frac{x_2}{2}$$

Аналогично для второй координаты:

$$\frac{\partial f}{\partial x_2} = 0, \quad 2x_1 + 6x_2 - 6 = 0$$

Отсюда:

$$x_2 = 1 - \frac{x_1}{3}$$

Таким образом, в программе последовательно выполнялись переходы:

$$x_1^{(k+1)} = 3 - \frac{x_2^{(k)}}{2}; \quad x_2^{(k+1)} = 1 - \frac{x_1^{(k+1)}}{3}$$

После каждой итерации проверялось условие: $\|\nabla f(x^{(k)})\| < 0.0001$
В результате метод покоординатного спуска сошёлся к точке: $x^* \approx (3,0)$

Метод градиентного спуска

Метод градиентного спуска использует направление антиградиента, то есть направление наибыстрейшего убывания функции. Общая формула метода:

$$x^{(k+1)} = x^{(k)} - \alpha \nabla f(x^{(k)})$$

В программе использовался постоянный шаг: $\alpha = 0.2$

На каждой итерации вычислялся градиент:

$$\nabla f(x_1, x_2) = \begin{pmatrix} 4x_1 + 2x_2 - 12 \\ 2x_1 + 6x_2 - 6 \end{pmatrix}$$

После этого строилось новое приближение.

Метод завершался при выполнении условия: $\|\nabla f(x^{(k)})\| < 0.0001$

В результате метод градиентного спуска сошёлся к точке: $x^* \approx (3,0)$

Метод наискорейшего спуска

Метод наискорейшего спуска также использует направление антиградиента, но в отличие от обычного градиентного спуска, шаг α_k выбирается на каждой итерации оптимально.

Формула метода:

$$x^{(k+1)} = x^{(k)} - \alpha_k \nabla f(x^{(k)})$$

Для квадратичной функции оптимальный шаг вычисляется по формуле:

$$\alpha_k = \frac{\nabla f(x^{(k)})^T \nabla f(x^{(k)})}{\nabla f(x^{(k)})^T H \nabla f(x^{(k)})}$$




где H — матрица Гессе: $H = \begin{pmatrix} 4 & 2 \\ 2 & 6 \end{pmatrix}$

Критерий остановки: $\|\nabla f(x^{(k)})\| < 0.0001$

В результате метод наискорейшего спуска также сошёлся к точке: $x^* \approx (3,0)$

Визуализация

Для каждого метода была построена визуализация. Линии уровня строились по значениям функции в точках приближений: $c_k = f(x^{(k)})$, $f(x_1, x_2) = c_k$:



Задание Д32.2

Найдите точку минимума функции по варианту численно методом Ньютона. Порог на модуль градиента функции для критерия останова: 0.0001. Выполните решение также аналитически – для каждой стационарной точки укажите тип экстремума. Представьте в отчете детализацию вычислений, реализуйте расчёты программно.
Данные по варианту: $z(x, y) = x^3 - 15x^2 + 72x + y^3 - 5y^2 + 7y - 115$, $(x_0, y_0) = (5.5, 2.5)$

Градиент и матрица Гессе

Найдём частные производные:

$$\frac{\partial z}{\partial x} = 3x^2 - 30x + 72; \quad \frac{\partial z}{\partial y} = 3y^2 - 10y + 7$$

Следовательно,

$$\nabla z(x, y) = \begin{pmatrix} 3x^2 - 30x + 72 \\ 3y^2 - 10y + 7 \end{pmatrix}$$

Матрица Гессе:

$$H(x, y) = \begin{pmatrix} 6x - 30 & 0 \\ 0 & 6y - 10 \end{pmatrix}$$

Аналитическое нахождение стационарных точек

Стационарные точки находятся из условия:

$$\nabla z(x, y) = 0$$

Получаем систему:

$$\begin{cases} 3x^2 - 30x + 72 = 0 \\ 3y^2 - 10y + 7 = 0 \end{cases}$$

Из первого уравнения: $x_1 = 4, x_2 = 6$

Из второго уравнения: $y_1 = 1, y_2 = \frac{7}{3}$

Стационарные точки: $(4, 1), (4, \frac{7}{3}), (6, 1), (6, \frac{7}{3})$

Определение типа стационарных точек

Для классификации используем матрицу Гессе:

$$H(x, y) = \begin{pmatrix} 6x - 30 & 0 \\ 0 & 6y - 10 \end{pmatrix}$$

Точка $(4, 1)$

$$H(4, 1) = \begin{pmatrix} 6 \cdot 4 - 30 & 0 \\ 0 & 6 \cdot 1 - 10 \end{pmatrix} = \begin{pmatrix} -6 & 0 \\ 0 & -4 \end{pmatrix}$$
$$\det H = (-6)(-4) = 24 > 0, \quad H_{11} = -6 < 0$$

Следовательно, точка $(4, 1)$ — локальный максимум.

Точка $(4, \frac{7}{3})$

$$H(4, \frac{7}{3}) = \begin{pmatrix} -6 & 0 \\ 0 & 4 \end{pmatrix}$$
$$\det H = (-6) \cdot 4 = -24 < 0$$

Следовательно, точка $(4, \frac{7}{3})$ — седловая точка.

Точка (6, 1)

$$H(6,1) = \begin{pmatrix} 6 & 0 \\ 0 & -4 \end{pmatrix}$$
$$\det H = 6 \cdot (-4) = -24 < 0$$

Следовательно, точка (6, 1) — седловая точка.

Точка $(6, \frac{7}{3})$

$$H\left(6, \frac{7}{3}\right) = \begin{pmatrix} 6 & 0 \\ 0 & 4 \end{pmatrix}$$
$$\det H = 6 \cdot 4 = 24 > 0, \quad H_{11} = 6 > 0$$

Следовательно, точка $(6, \frac{7}{3})$ — локальный минимум.

Метод Ньютона

Метод Ньютона для функции двух переменных имеет вид:

$$X_{k+1} = X_k - H^{-1}(X_k) \nabla z(X_k)$$

Критерий остановки: $\|\nabla z(X_k)\| < 0.0001$

Ручное вычисление первой итерации

Начальная точка: $x_0 = 5.5, y_0 = 2.5$

Вычислим градиент:

$$\nabla z(5.5, 2.5) = \begin{pmatrix} 3 \cdot 5.5^2 - 30 \cdot 5.5 + 72 \\ 3 \cdot 2.5^2 - 10 \cdot 2.5 + 7 \end{pmatrix} = \begin{pmatrix} -2.25 \\ 0.75 \end{pmatrix}$$

Вычислим матрицу Гессе:

$$H(5.5, 2.5) = \begin{pmatrix} 6 \cdot 5.5 - 30 & 0 \\ 0 & 6 \cdot 2.5 - 10 \end{pmatrix} = \begin{pmatrix} 3 & 0 \\ 0 & 5 \end{pmatrix}$$

Для метода Ньютона нужно решить систему:

$$H(X_0) \Delta X_0 = \nabla z(X_0)$$
$$\begin{pmatrix} 3 & 0 \\ 0 & 5 \end{pmatrix} \begin{pmatrix} \Delta x \\ \Delta y \end{pmatrix} = \begin{pmatrix} -2.25 \\ 0.75 \end{pmatrix}$$

Отсюда:

$$\Delta x = \frac{-2.25}{3} = -0.75$$
$$\Delta y = \frac{0.75}{5} = 0.15$$

Следующее приближение:

$$X_1 = X_0 - \Delta X_0$$
$$x_1 = 5.5 - (-0.75) = 6.25$$
$$y_1 = 2.5 - 0.15 = 2.35$$

Получаем:

$$X_1 = (6.25, 2.35)$$

Таблица итераций метода Ньютона

k	x_k	y_k	$z(x_k, y_k)$	z'_x	z'_y	$\ \nabla z\ $
0	5.50000000	2.50000000	-4.50000000	-2.25000000	0.75000000	2.37170825
1	6.25000000	2.35000000	-4.98150000	1.68750000	0.06750000	1.68884946
2	6.02500000	2.33353659	-5.18329448	0.15187500	0.00081313	0.15187718
3	6.00030488	2.33333336	-5.18518491	0.00182955	0.00000012	0.00182955
4	6.00000005	2.33333333	-5.18518519	0.00000028	0.00000000	0.00000028

Результаты работы программы

Начальное приближение: $X_0 = (5.5, 2.5)$

Метод Ньютона сошёлся к точке: $X^* = \left(6, \frac{7}{3}\right)$

В десятичном виде: $X^* \approx (6.000000, 2.333333)$

Значение функции: $z(X^*) \approx -5.185185$

Норма градиента в найденной точке: $\|\nabla z(X^*)\| = 0.00000028 < 0.0001$

Задание Д32.3

Постройте объектную модель задачи минимизации функции двух переменных методами покоординатного, градиентного и наискорейшего спуска: выполните постановку задачи, введите сущности (классы), их атрибуты и методы. Задайте иерархию классов так, чтобы абстрактные классы (и/или интерфейсы) и конкретные классы охватывали логику трёх методов из ЛР4. Воспользуйтесь отношениями наследования, реализации, композиции, агрегации, зависимости, использования – несколько по своему выбору. Выполните проектирование и обновите программную реализацию с учетом объектной модели (Python).

Постановка задачи оптимизации

Требуется найти точку минимума функции: $f(x_1, x_2) \rightarrow \min$

Для данной функции градиент равен: $\nabla f(x_1, x_2) = \begin{pmatrix} 4x_1 + 2x_2 - 12 \\ 2x_1 + 6x_2 - 6 \end{pmatrix}$

Матрица Гессе: $H = \begin{pmatrix} 4 & 2 \\ 2 & 6 \end{pmatrix}$

Так как матрица Гессе положительно определена, функция является выпуклой квадратичной функцией и имеет единственную точку минимума.

Выделение сущностей объектной модели

Для объектной модели были выделены следующие основные сущности:

Класс Problem — описывает задачу оптимизации. Он содержит начальную точку и методы для вычисления значения функции, градиента и матрицы Гессе.

Атрибуты:

Атрибут	Назначение
start_point	начальное приближение

Методы:

Метод	Назначение
f(point)	вычисляет значение целевой функции
grad(point)	вычисляет градиент функции
hessian()	возвращает матрицу Гессе

Класс Optimizer — является базовым классом для всех методов оптимизации.

Атрибуты:

Атрибут	Назначение
problem	объект задачи оптимизации
eps	точность критерия останова
max_iter	максимальное количество итераций
name	название метода

Методы:

Метод	Назначение
solve()	выполняет общий итерационный процесс
step(point, iteration)	выполняет один шаг метода

Класс CoordinateDescent — наследуется от Optimizer и реализует метод покоординатного спуска.

На чётных итерациях обновляется первая координата: $x_1 = 3 - \frac{x_2}{2}$

На нечётных итерациях обновляется вторая координата: $x_2 = 1 - \frac{x_1}{3}$

Таким образом, метод последовательно минимизирует функцию по одной координате.

Класс GradientDescent — наследуется от Optimizer и реализует метод градиентного спуска.

Формула перехода: $x^{(k+1)} = x^{(k)} - \alpha \nabla f(x^{(k)})$

В программе использовался постоянный шаг: $\alpha = 0.2$

Класс SteepestDescent — наследуется от Optimizer и реализует метод наискорейшего спуска.

Формула перехода: $x^{(k+1)} = x^{(k)} - \alpha_k \nabla f(x^{(k)})$

Оптимальный шаг для квадратичной функции вычисляется по формуле:

$$\alpha_k = \frac{\nabla f(x^{(k)})^T \nabla f(x^{(k)})}{\nabla f(x^{(k)})^T H \nabla f(x^{(k)})}$$

Класс Result — хранит результат работы метода оптимизации.


Атрибуты:

Атрибут	Назначение
method_name	название метода
Points	последовательность приближений
problem	объект задачи оптимизации

Методы:

Метод	Назначение
print_table()	выводит таблицу итераций
print_final()	выводит итоговый результат

UML-схема объектной модели



Результаты работы объектной модели

Объектная реализация была применена к функции: $f(x_1, x_2) = 2x_1^2 + 2x_1x_2 + 3x_2^2 - 12x_1 - 6x_2 + 18$, $x^{(0)} = (-2, 4)$

Для всех трёх методов были получены последовательности приближений.

Результат: $x^* \approx (3, 0)$, $f(x^*) \approx 0$

Таким образом, объектная реализация даёт тот же результат, что и обычная программная реализация.

Вывод по Блоку №2

В ходе выполнения заданий были рассмотрены численные методы безусловной оптимизации функции двух переменных. Для функции были реализованы и визуализированы методы покоординатного спуска, градиентного спуска и наискорейшего спуска. Все методы сошлись к точке минимума: $x^* = (3, 0)$.

Также была решена отдельная задача методом Ньютона. Аналитически были найдены все стационарные точки функции и определены их типы с помощью матрицы Гессе. Метод Ньютона сошёлся к точке локального минимума: $(6, \frac{7}{3})$.

Кроме того, была построена объектная модель задачи оптимизации, в которой общая логика методов вынесена в базовый класс, а конкретные методы реализованы через наследование.

Блок №3

Задание

Исследуйте пример из дополнительных материалов к Лекции 6: UFSACO.ipynb, данные samples.pkl, комментарии (Лекция 6. Комментарии к коду (FS).docx). Этот кейс – отбор значимых признаков при моделировании содержания меди в продуктах обработки «Норильского никеля» (пенная флотация). Решите аналогичную задачу, используя тот же код для своих данных.

Выберите датасет на одном из порталов, являющихся агрегаторами задач машинного обучения, тип задачи – регрессия.

Выберите также целевой признак (он может быть уже выбран – смотрите описание датасета, используйте его или назначьте понравившийся вещественный признак целевым). Дайте в произвольной форме описание датасета (см пример, информация из описания на портале, полученная из этапов разведочного анализа и т.д.): важно понимать, какая предметная область, с какими признаками имеем дело.

С помощью градиентного бустинга (используем как черный ящик) определите значимые признаки для моделирования выбранного. А с помощью метода муравьиной колонии отберите признаки для задачи без целевого признака.

Убедитесь, что пересечение двух множеств признаков, найденных этими способами, не является пустым (мощность пересечения не менее 4 элементов). Если это требование не выполнено, поварьируйте гиперпараметры алгоритма муравьиной колонии.

Описание выбранного датасета

Для выполнения задания был выбран датасет: Online News Popularity

Данный датасет относится к задаче регрессии. Он содержит информацию об онлайн-

новостях, опубликованных на сайте Mashable. Для каждой статьи представлены числовые характеристики текста, метаданные, признаки тематики, признаки дня публикации, а также показатели тональности текста.

Признак shares показывает количество репостов статьи в социальных сетях. Таким образом, задача состоит в том, чтобы по характеристикам статьи определить её популярность.

В рамках работы признак shares используется как целевой признак, а остальные числовые признаки используются как входные признаки модели.

Характеристика	Значение
Тип задачи	регрессия
Целевой признак	shares
Количество объектов	39644
Количество исходных столбцов	61
Количество признаков после подготовки	58
Количество отбираемых признаков	15

Предварительная обработка данных

Перед применением методов отбора признаков была выполнена предварительная подготовка данных.

Были удалены непредиктивные признаки:

- Признак url был удалён, так как он содержит ссылку на статью и не является числовой характеристикой текста.
- Признак timedelta также был исключён из дальнейшего анализа.

Далее был выделен целевой признак: shares, который показывает количество репостов статьи в социальных сетях.

Матрица признаков была сформирована из всех оставшихся числовых признаков: X

Целевой признак был сохранён отдельно: y

Для метода UFSACO дополнительно была создана нормированная матрица признаков:

X_{scaled}

Нормирование выполнялось с помощью метода MinMaxScaler, который приводит значения признаков к диапазону от 0 до 1.

Итоговые размеры данных после подготовки:

Объект	Размер
X	(39644, 58)
X_{scaled}	(39644, 58)
y	(39644,)

Отбор признаков с помощью Gradient Boosting

Для определения признаков, наиболее важных для моделирования целевого признака shares, был использован метод Gradient Boosting.

Градиентный бустинг в данной работе используется как модель типа «чёрный ящик». После обучения модели можно получить значения важности признаков. Чем больше значение важности признака, тем сильнее данный признак влияет на качество моделирования целевого признака.

Идея метода Gradient Boosting

Gradient Boosting — это ансамблевый метод, который строит итоговую модель как сумму нескольких деревьев решений:

$$F(x) = \sum_{n=1}^N \gamma_n h_n(x)$$

где $h_n(x)$ — отдельное дерево, γ_n — вес дерева, N — количество деревьев.

Каждое новое дерево обучается исправлять ошибки предыдущих. Для регрессии обычно используется квадратичная функция потерь:

$$L(y, F(x)) = (y - F(x))^2$$

На каждой итерации вычисляется ошибка модели:

$$r_i = y_i - F_{n-1}(x_i)$$

Затем новое дерево $h_n(x)$ обучается предсказывать эти остатки:

$$h_n(x_i) \approx r_{in}$$

После этого модель обновляется:

$$F_n(x) = F_{n-1}(x) + \eta \gamma_n h_n(x)$$

где η — скорость обучения, γ_n — коэффициент шага, $h_n(x)$ — новое дерево.

После обучения модели можно получить важность признаков: I_j

Тогда множество выбранных признаков определяется как признаки с наибольшими значениями важности:

$$GB = Top_N(I_j)$$

где GB — множество выбранных признаков, N — количество выбираемых признаков, I_j — важность j -го признака.

Параметры модели

Параметр	Значение	Назначение
n_estimators	300	количество деревьев в ансамбле
max_depth	4	максимальная глубина дерева
min_samples_split	10	минимальное число объектов для разделения узла
learning_rate	0.01	скорость обучения
random_state	42	фиксирует воспроизводимость результата

Результаты отбора признаков

После обучения модели были рассчитаны важности всех 58 признаков. Затем были выбраны 15 наиболее значимых признаков.

№	Признак	Важность
1	title_subjectivity	0.143252
2	average_token_length	0.137463
3	kw_avg_avg	0.098854
4	self_reference_avg_sharess	0.097168
5	n_tokens_content	0.059577
6	LDA_03	0.052407

7	self reference min shares	0.044604
8	n_non_stop_unique_tokens	0.041579
9	kw_max_max	0.037337
10	n_unique_tokens	0.037273
11	LDA_00	0.032995
12	kw_max_avg	0.027791
13	avg_negative_polarity	0.026647
14	kw_max_min	0.018422
15	weekday_is_saturday	0.018293

Наиболее важными оказались признаки, связанные с субъективностью заголовка, средней длиной токенов, статистиками ключевых слов и количеством ссылок на другие статьи. Всего для дальнейшего сравнения было выбрано 15 признаков.

Отбор признаков с помощью UFSACO

Вторым методом отбора признаков был использован метод UFSACO — метод отбора признаков на основе алгоритма муравьиной колонии. В отличие от Gradient Boosting, метод UFSACO выполняет отбор признаков без использования целевого признака. Метод анализирует только матрицу признаков X_{scaled} — нормированная матрица признаков.

Каждый признак рассматривается как узел графа. Муравьи перемещаются между признаками, выбирая признаки с учётом феромона и меры схожести признаков. В результате признаки, которые чаще выбираются муравьями, получают большее значение феромона.

Идея метода UFSACO

Перед применением UFSACO данные были нормированы с помощью MinMaxScaler. Формула нормирования:

$$x_{scaled} = \frac{x - x_{min}}{x_{max} - x_{min}}$$

Каждый признак рассматривается как узел графа. Муравьи переходят между признаками и оставляют феромон.

Для оценки схожести признаков используется косинусная мера, где X_i и X_j — векторы значений признаков:

$$s_{ij} = \frac{|X_i^T X_j|}{\|X_i\| \cdot \|X_j\|}$$

Оценка перехода к признаку j :

$$score_j = \frac{\tau_j}{s_{ij}^\alpha}$$

где τ_j — феромон признака, s_{ij} — схожесть признаков.

Вероятность выбора признака:

$$p_j = \frac{score_j}{\sum score_j}$$

Феромон обновляется по формуле:

$$\tau_j^{new} = (1 - \rho)\tau_j + \frac{visits_j}{\sum visits}$$

После завершения выбираются признаки с наибольшими значениями феромона:

$$UFSACO = Top_N(\tau_j)$$

Параметры алгоритма:

Параметр	Значение	Назначение
N_FEATURES	15	количество отбираемых признаков
NC_MAX	3	количество циклов алгоритма
N_STEPS	4	количество шагов муравьёв
INIT_PHEROMONE	0.2	начальное значение феромона
RO	0.2	коэффициент испарения феромона
EXPLOITATION_PROB	0.7	вероятность выбора лучшего перехода
ALPHA	1.0	степень влияния схожести признаков
N_ANTS	5	количество муравьёв
UFSACO_RANDOM_STATE	28	фиксирует воспроизводимость результата

Результаты отбора признаков

В результате работы метода UFSACO было выбрано 15 признаков.

№	Признак	Значение феромона
1	data_channel_is_lifestyle	0.8624
2	data_channel_is_world	0.5684
3	data_channel_is_entertainment	0.3144
4	n_unique_tokens	0.3104
5	data_channel_is_tech	0.2644
6	data_channel_is_bus	0.2344
7	data_channel_is_socmed	0.2144
8	self_reference_min_shares	0.1664
9	avg_positive_polarity	0.1524
10	n_non_stop_unique_tokens	0.1524
11	weekday_is_wednesday	0.1424
12	weekday_is_monday	0.1424
13	self_reference_avg_share	0.1424
14	weekday_is_tuesday	0.1424
15	LDA_03	0.1344

Сравнение результатов

После выполнения отбора признаков двумя методами были получены два множества признаков:

- GB — множество признаков, выбранных методом Gradient Boosting;
- UFSACO — множество признаков, выбранных методом муравьиной колонии UFSACO.

Для проверки результата было найдено пересечение множеств $GB \cap UFSACO$
Количество общих признаков: $|GB \cap UFSACO| = 5$

Таблица сравнения признаков

№	Gradient Boosting	UFSACO	Пересечение
1	title_subjectivity	data_channel_is_lifestyle	LDA_03
2	average_token_length	data_channel_is_world	n_non_stop_unique_tokens
3	kw_avg_avg	data_channel_is_entertainment	n_unique_tokens
4	self_reference_avg_sharess	n_unique_tokens	self_reference_avg_sharess
5	n_tokens_content	data_channel_is_tech	self_reference_min_shares
6	LDA_03	data_channel_is_bus	
7	self_reference_min_shares	data_channel_is_socmed	
8	n_non_stop_unique_tokens	self_reference_min_shares	
9	kw_max_max	avg_positive_polarity	
10	n_unique_tokens	n_non_stop_unique_tokens	
11	LDA_00	weekday_is_wednesday	
12	kw_max_avg	weekday_is_monday	
13	avg_negative_polarity	self_reference_avg_sharess	
14	kw_max_min	weekday_is_tuesday	
15	weekday_is_saturday	LDA_03	

Вывод по Блоку №3

В ходе выполнения задания была решена задача отбора значимых признаков для датасета Online News Popularity. В качестве целевого признака был выбран признак: shares, который показывает количество репостов статьи в социальных сетях. После предварительной обработки данных было получено 39644 объекта и 58 признаков. Для отбора было выбрано 15 признаков.

Отбор признаков был выполнен двумя методами:

1. Gradient Boosting — с использованием целевого признака shares;
2. UFSACO — без использования целевого признака.

Gradient Boosting определил признаки, наиболее важные для моделирования количества репостов статьи. Метод UFSACO выбрал признаки на основе алгоритма муравьиной колонии, используя только нормированную матрицу признаков. В результате сравнения двух множеств признаков было найдено пересечение из 5 элементов.

Таким образом, можно сделать вывод, что оба метода выделили несколько общих значимых признаков. Наиболее устойчивыми оказались признаки, связанные с тематикой статьи, уникальностью слов и ссылками на другие статьи. Эти признаки можно считать важными для анализа популярности онлайн-новостей.